ỦY BAN NHÂN DÂN TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN

BÁO CÁO CUỐI KỲ
PHƯƠNG PHÁP NGHIÊN CỨU KHOA HỌC TRONG CÔNG NGHỆ THÔNG TIN

ĐÁNH GIÁ GIÁ TRỊ BỔ SUNG CỦA THÔNG TIN HỌC KỲ THỨ NHẤT TRONG DỰ BÁO NGUY CƠ BỎ HỌC CỦA SINH VIÊN TRÊN DỮ LIỆU UCI 697

NHÓM 4 – LỚP DCT123C4
Lý Đức Huy – 3123411114
Nguyễn Quốc Huy – 3123411120
Trần Nam Khang – 3123411144
Võ Quốc Khánh – 3123411151
Lâm Trác Đạt – 3123411064

NGÀNH: CÔNG NGHỆ THÔNG TIN
TRÌNH ĐỘ ĐÀO TẠO: ĐẠI HỌC

TP. HỒ CHÍ MINH, THÁNG 11 NĂM 2026

MỤC LỤC

1 Giới thiệu 3

1.1 Bối cảnh và lý do chọn đề tài 3

1.2 Vấn đề và câu hỏi nghiên cứu 3

1.3 Phạm vi và cách hiểu kết quả 3

2 Tổng quan nghiên cứu 4

2.1 Từ ý tưởng đến từ khóa và tài liệu 4

2.2 Nội dung và vai trò của từng bài báo 5

2.3 Bảng so sánh các công trình 6

2.4 So sánh theo chiều dọc từng tiêu chí 8

2.5 Vấn đề được chọn và hướng đề xuất 9

3 Phương pháp đề xuất 10

3.1 Mục tiêu nghiên cứu 10

3.2 Dữ liệu và biến nghiên cứu 10

3.3 Thiết kế so sánh và chia dữ liệu 11

3.4 Tiền xử lý và mô hình 11

3.5 Tiêu chí đánh giá 12

3.6 Phân tích lỗi và giới hạn diễn giải 13

4 Kế hoạch thực hiện 13

4.1 Các giai đoạn và sản phẩm kiểm tra 13

4.2 Phân công dự kiến 14

4.3 Nguồn lực và phương án khi gặp khó khăn 14

5 Kết quả dự kiến 15

5.1 Sản phẩm đầu ra 15

5.2 Kết quả mong đợi và cách kết luận 15

5.3 Tính khả thi và điều kiện hoàn thành 15

Tài liệu tham khảo 16

Phụ lục đối chiếu nguồn 17

CÁCH ĐỌC BÁO CÁO

Báo cáo gồm phần tổng quan năm bài báo và đề cương thực nghiệm. P1–P5 tương ứng tài liệu [1]–[5]. Những kết quả có trích dẫn là số liệu của tác giả; các cấu hình T0–T1, kế hoạch và sản phẩm thực nghiệm là đề xuất của nhóm, chưa phải kết quả đã chạy.

Bảng 1 Giải thích ký hiệu

Ký hiệu	**Ý nghĩa**
T0 / T1	Thông tin đầu vào / thông tin đầu vào cộng thông tin học kỳ một.
LR / RF / BRF	Logistic Regression / Random Forest / Balanced Random Forest.
NN / DNN / SVM	Mạng nơ-ron / mạng nơ-ron sâu / máy véc-tơ hỗ trợ.
LMS	Hệ thống quản lý học tập, nguồn nhật ký hoạt động học.
SMOTE	Kỹ thuật tạo mẫu tổng hợp cho lớp thiểu số.
AUC	Diện tích dưới đường cong ROC trong bài P4; khác accuracy.
Macro-F1	Trung bình F1 không trọng số giữa các lớp.
Fold / seed	Phần dữ liệu trong kiểm định chéo / hạt giống sinh số ngẫu nhiên.

1 Giới thiệu

1.1 Bối cảnh và lý do chọn đề tài

Dự báo nguy cơ bỏ học có thể cung cấp thông tin để nhà trường cân nhắc hỗ trợ sinh viên. Tuy nhiên, một mô hình dự báo tốt phải được đánh giá theo thông tin thực sự có tại thời điểm sử dụng. Điểm học kỳ hai có thể giúp nhận diện sinh viên bỏ học trong dữ liệu lịch sử, nhưng không thể dùng để đưa ra dự báo ngay lúc nhập học. Vì vậy, thời điểm quan sát và giá trị bổ sung của từng nhóm thông tin là vấn đề trung tâm của đề tài.

Nhóm lựa chọn ý tưởng đánh giá giá trị bổ sung của thông tin học kỳ thứ nhất đối với phân loại tình trạng học tập trên bộ dữ liệu UCI 697. Bài giữa kỳ tập trung phân tích công trình công bố dữ liệu của Realinho và cộng sự [1]. Bài cuối kỳ mở rộng sang năm bài báo [1]–[5], đối chiếu cách thiết kế thực nghiệm, sau đó xây dựng một đề cương có thể triển khai bằng dữ liệu công khai [6]. Kho dữ liệu UCI là nguồn dữ liệu riêng, không được tính vào năm bài báo.

Các công trình đã đọc cho thấy kết quả học tập có giá trị dự báo, nhưng cách định nghĩa bỏ học, lựa chọn thời điểm và đánh giá khác nhau đáng kể. Martins và cộng sự đã nghiên cứu dự báo theo giai đoạn [3]; do đó, nhóm không coi việc bổ sung điểm học kỳ một là một ý tưởng hoàn toàn mới. Đóng góp dự kiến là một thực nghiệm kiểm chứng trong phạm vi học phần, với cùng tập sinh viên, cùng cách chia tập và quy trình xử lý có thể kiểm tra lại.

1.2 Vấn đề và câu hỏi nghiên cứu

Câu hỏi chính là: khi giữ nguyên tập sinh viên và cách đánh giá, bổ sung thông tin học kỳ một vào thông tin đầu vào có cải thiện macro-F1 và khả năng nhận diện lớp Dropout hay không? Hai câu hỏi phụ là mức cải thiện có nhất quán giữa Logistic Regression và Random Forest không, và các lỗi dự báo thường nhầm Dropout với Enrolled hay với Graduate.

Nhóm dự kiến kiểm tra giả thuyết rằng thông tin học kỳ một giúp phân biệt tốt hơn những sinh viên có cùng hồ sơ nhập học nhưng tiến độ học tập khác nhau. Đây là giả thuyết cần thực nghiệm, không phải kết luận đã được xác nhận cho bộ biến và cách chia tập của nhóm. Trường hợp cải thiện nhỏ, không rõ hoặc âm vẫn phải được báo cáo.

1.3 Phạm vi và cách hiểu kết quả

Đối tượng phân tích là dữ liệu lịch sử của cơ sở giáo dục đại học tại Portalegre, Bồ Đào Nha. Phân tích chính giữ ba nhãn Dropout, Enrolled và Graduate. Enrolled chỉ có nghĩa còn theo học tại thời điểm kết thúc thời lượng chuẩn của chương trình; không đồng nghĩa chắc chắn sẽ tốt nghiệp [1]. Nhóm không thu thập hồ sơ sinh viên của Trường Đại học Sài Gòn và không khẳng định mô hình đã phù hợp với sinh viên Việt Nam.

Hai tập biến được ký hiệu T0 và T1 để mô phỏng hai mức thông tin: hồ sơ đầu vào và hồ sơ đầu vào cộng thông tin học kỳ một. Bộ dữ liệu công khai không có ngày bỏ học để xác định đầy đủ ai còn theo học tại mốc T1. Do đó, nghiên cứu là đánh giá hồi cứu giá trị của thông tin, chưa phải kiểm chứng một hệ thống cảnh báo sớm trong vận hành. Các trường hợp đã bỏ học trước khi hết học kỳ một có thể tạo dấu hiệu quá dễ nhận diện; hạn chế này phải đi cùng kết luận.

Trong báo cáo, phần tổng quan sử dụng kết quả đã công bố trong các bài báo. Phần phương pháp, kế hoạch và kết quả dự kiến mô tả công việc nhóm đề xuất thực hiện. Nhóm chưa huấn luyện các mô hình của đề cương này và chưa có số đo hiệu năng thực nghiệm riêng.

2 Tổng quan nghiên cứu

2.1 Từ ý tưởng đến từ khóa và tài liệu

Ý tưởng được tách thành ba nhóm khái niệm: đối tượng là sinh viên đại học có nguy cơ bỏ học; kỹ thuật là học máy trên dữ liệu dạng bảng; trọng tâm là thời điểm dự báo, thông tin học kỳ một và đánh giá trong điều kiện mất cân bằng lớp. Cách tách này giúp tìm những bài giải quyết cùng vấn đề kỹ thuật thay vì chỉ trùng cụm từ trong tiêu đề.

Nhóm	**Từ khóa hoặc chuỗi truy vấn**
Vấn đề	student dropout prediction; academic success; higher education; dự đoán sinh viên bỏ học
Thời điểm	early prediction; phased prediction; first semester; pre-enrollment data
Kỹ thuật	machine learning; Random Forest; logistic regression; class imbalance; data leakage
Truy vấn kết hợp	"student dropout" AND "higher education" AND "first semester"; "Multi-Class Phased Prediction"; "dropout prediction" AND "oversampling"
Truy vấn tiếng Việt	"dự đoán" "bỏ học" "sinh viên" "học máy"

Nhóm tìm thông tin thư mục và đường dẫn trên trang nhà xuất bản, trang hội nghị và kho lưu trữ; sau đó tải toàn văn PDF về máy trước khi trích xuất, đọc và lập bảng. Các bài [1], [2] đã có trong tài liệu của bản trước; các bài [3]–[5] được bổ sung cho lần tổng quan này. Ngày hoàn tất đợt tìm và đối chiếu là 06/11/2026. Nội dung phân tích không lấy từ đoạn mô tả của kết quả tìm kiếm.

Tiêu chí chọn gồm: có toàn văn; nghiên cứu liên quan đến bỏ học hoặc tình trạng học tập trong giáo dục đại học; có mô tả dữ liệu, phương pháp hoặc cách đánh giá đủ để đối chiếu; và có vai trò rõ trong đề tài. Bài [1] là bài mô tả dữ liệu nền tảng, còn [2]–[5]

là các nghiên cứu thực nghiệm. Các trang chỉ giới thiệu dữ liệu, bài không có toàn văn và nghiên cứu chỉ dự đoán điểm một môn không phù hợp với trọng tâm được loại khỏi bộ năm bài. Đây là tổng quan có chủ đích phục vụ đề cương, không phải tổng quan hệ thống bao quát toàn bộ lĩnh vực.

Trong phần sau, P1–P5 lần lượt tương ứng với tài liệu [1]–[5]. Vị trí trang ghi theo thứ tự trang của tệp PDF, bắt đầu từ trang 1. Riêng bài P2, trang PDF 4 tương ứng trang in 123; bài P4 bắt đầu ở trang in 349. Sổ đối chiếu ở phụ lục giúp truy lại các số liệu chính.

2.2 Nội dung và vai trò của từng bài báo

P1 Bài công bố dữ liệu của Realinho và cộng sự

Realinho và cộng sự [1] mô tả cách kết hợp nguồn tuyển sinh, hồ sơ học tập và dữ liệu kinh tế, làm sạch và xây dựng nhãn cho 4.424 hồ sơ. Bài phân tích mất cân bằng, tương quan và permutation importance bằng bốn mô hình tổ hợp cây với F1. Đây là nguồn để hiểu dữ liệu, không phải bảng chuẩn accuracy để xếp hạng mô hình. Các biến học kỳ hai trong bài không được chuyển sang kịch bản T1. Đối chiếu: trang 3–4, 7 và 10–11.

P2 Nghiên cứu trong nước của Nông Thị Hoa

Nông Thị Hoa [2] thử NN, RF và SVM trên UCI, gộp Enrolled với Graduate rồi báo cáo RF đạt accuracy 0,9133. Mục 2.2 mô tả nhân đôi Dropout trước chia tập, tạo nguy cơ bản sao có mặt trong cả huấn luyện lẫn kiểm tra. Trang PDF 4 ghi 1.169 mẫu kiểm tra nhưng ma trận RF cộng thành 1.754. Nhóm dùng bài để tham khảo mô hình và kiểm tra phương pháp, không lấy 0,9133 làm chuẩn phải đạt. Nguồn dữ liệu vẫn là nước ngoài.

P3 Nghiên cứu dự báo theo giai đoạn của Martins và cộng sự

Martins và cộng sự [3] sử dụng dữ liệu gốc 4.433 sinh viên, xây dựng S0 lúc nhập học, S1 cuối học kỳ một và S2 cuối học kỳ hai. Bài so sánh năm phương pháp kết hợp học máy và cân bằng lớp, chia 90/10, dùng CV và lặp seed. Tại S1, SVMSMOTE + RF có Test F1 Score 0,745 ± 0,014. Không đổi tên "global F1" thành macro-F1 khi cách lấy trung bình chưa rõ. Việc loại hồ sơ đã bỏ học ở giai đoạn sau làm thay đổi thành phần mẫu, gợi ý nhóm cần tách ảnh hưởng của tập biến khỏi ảnh hưởng của tập mẫu. Đối chiếu: trang 4–9.

P4 Nghiên cứu theo thời điểm và ngành của Goren và cộng sự

Goren, Cohen và Rubinstein [4] nghiên cứu 8.267 sinh viên giai đoạn 2019–2022, kết hợp dữ liệu đầu vào, LMS và kết quả học tập. XGBoost và NN được đánh giá tại nhiều mốc bằng AUC và recall Dropout. Riêng ngành khoa học máy tính, XGBoost

không LMS có AUC 0,63 ở Pre-Entry và 0,86 sau kỳ thi B. Lợi ích của LMS phụ thuộc mô hình và thời điểm; kết quả một phân nhóm không đại diện tự động cho toàn bộ mẫu. Đối chiếu: trang 3–7 và phụ lục trang 10.

P5 Nghiên cứu mất cân bằng lớp của Cho và cộng sự

Cho, Yu và Kim [5] tổng hợp khoảng 168.000 bản ghi học kỳ của 20.050 sinh viên, rồi so sánh sáu mô hình. Bảng 8 báo cáo LightGBM đạt accuracy 0,955 và F1 lớp bỏ học 0,840. SMOTE chỉ cải thiện nhẹ F1 của RF; không có kết quả LightGBM + SMOTE do lỗi tương thích. Bài dùng nhiều biến học kỳ cuối và chuẩn hóa toàn bộ X trước chia tập trong đoạn mã, nên không thể xem điểm số là bằng chứng cho cảnh báo ngay lúc nhập học. Đối chiếu: trang 5–8 và 10–15.

2.3 Bảng so sánh các công trình

Bảng 2 đối chiếu năm bài trên cùng hệ tiêu chí. Số đo được trích từ bài gốc, chưa được nhóm tái lập; nhận xét về hạn chế là đánh giá của nhóm. Không xếp thứ hạng chung giữa các bài khác dữ liệu hoặc nhãn.

Bảng 2 So sánh năm bài báo theo các tiêu chí kỹ thuật

Bài	Dữ liệu và thời điểm	Tiền xử lý	Mô hình và đánh giá	Kết quả tác giả báo cáo	Ưu điểm và hạn chế
P1 [1]	4.424 hồ sơ Portalegre. Ba lớp. Biến nhập học và hai học kỳ; 34 biến đầu vào trong bài mô tả.	Ghép nguồn; làm sạch, loại trùng, ẩn danh; phân tích mất cân bằng và tương quan.	RF, XGBoost, LightGBM, CatBoost để khảo sát permutation importance theo F1. Không có giao thức benchmark đủ chi tiết.	Graduate 2.209; Dropout 1.421; Enrolled 794. Biến học phần đạt và học phí nổi bật. Không lấy accuracy làm mốc.	Ưu: mô tả và công bố dữ liệu. Hạn chế: không có ngày bỏ học; không suy diễn sẵn hiệu năng cảnh báo sớm. Tr. 3–4, 7, 10–11.
P2 [2]	UCI 4.424 hồ sơ, 36 biến. Gộp Graduate và Enrolled. Có thông tin cả học kỳ hai.	Mã hóa nhãn, chuẩn hóa; mô tả nhân đôi Dropout trước chia tập; xem xét đặc trưng quan trọng.	NN, RF, SVM. Chia 80/20 trên dữ liệu đã cân bằng; thử một số cấu hình. Chỉ số chính accuracy.	RF accuracy 0,9133. Bài ghi 1.169 mẫu kiểm tra; ma trận RF cộng thành 1.754. Không dùng làm mốc trực tiếp.	Ưu: đối chiếu thuật toán, có tham số và ma trận. Hạn chế: nguy cơ bản sao giữa các tập; số mẫu thiếu nhất quán; nhãn nhị phân. Tr. 3–5.
P3 [3]	4.433 hồ sơ gốc. Ba lớp; S0, S1, S2. Loại hồ sơ đã bỏ học khỏi các giai đoạn sau, làm thay đổi thành phần mẫu.	SMOTE hoặc SVMSMOTE với RF; hoặc cân bằng trong thuật toán. SMOTE được mô tả áp dụng trên tập huấn luyện.	SMOTE+RF, SVMSMOTE+RF, BRF, EE, RB. Chia 90/10 phân tầng; CV 10 phần; lặp 10 seed.	S1: SVMSMOTE+RF Test F1 0,745 ± 0,014; BRF F1 Dropout 0,728 ± 0,026. Giữ tên global F1 của bài.	Ưu: so sánh theo giai đoạn, có độ phân tán và điểm từng lớp. Hạn chế: tập mẫu thay đổi; không đồng nhất với CSV UCI hiện dùng. Tr. 4–9.
P4 [4]	8.267 sinh viên, 2019–2022; nhiều ngành. Bỏ học: không đăng ký môn 2 năm liên tiếp, chưa hoàn thành chương trình. Nhiều mốc từ 4 tuần.	Điền thiếu; chuẩn hóa theo môn; gom môn bằng k-means; đặc trưng studentship từ LMS. XGBoost dùng SMOTE; NN dùng trọng số loss.	XGBoost và NN; chia ngẫu nhiên 80/20; GridSearch cho XGBoost. AUC, recall Dropout và importance theo nhóm biến.	Riêng ngành CS, XGBoost không LMS: AUC Pre-Entry 0,63; Exam B 0,86. Lợi ích LMS phụ thuộc mô hình và thời điểm.	Ưu: xem xét thời gian, ngành, nhóm thông tin. Hạn chế: dữ liệu nội bộ; đặc trưng phức tạp; cần làm rõ phạm vi fit các bước tổng hợp khi tái lập. Tr. 3–7, 10.
P5 [5]	20.050 sinh viên; khoảng 168.000 bản ghi học kỳ. Nhị phân, nhiều biến của học kỳ cuối; tổng hợp theo sinh viên.	Làm trơn điểm, chọn biến tương quan, StandardScaler trước chia tập trong đoạn mã; thử SMOTE, ADASYN, Borderline-SMOTE.	LR, DT, RF, SVM, DNN, LightGBM. Chia 80/20; bảng kết quả là trung bình 5 lần. Accuracy, precision, recall, F1.	LightGBM: accuracy 0,955; F1 Dropout 0,840. RF F1 0,827 → 0,830 khi SMOTE. Không có kết quả LightGBM+SMOTE.	Ưu: khảo sát chỉ số lớp dương và tác động oversampling. Hạn chế: chuẩn hóa trước chia; biến học kỳ cuối không chứng minh dự báo sớm. Tr. 5–8, 10–15.

2.4 So sánh theo chiều dọc từng tiêu chí

Dữ liệu và khả năng tái lập

P1 cung cấp cơ sở dữ liệu công khai để nhóm có thể kiểm tra trực tiếp; P2 sử dụng UCI nên thuận lợi đối chiếu. P3 cùng bối cảnh Portalegre nhưng nêu 4.433 hồ sơ gốc và thay đổi tập mẫu theo giai đoạn, vì vậy không thể coi là cùng phiên bản CSV 4.424 dòng. P4 và P5 mở rộng sang các cơ sở khác với dữ liệu nội bộ và cách tổng hợp riêng. Chênh lệch cỡ mẫu không chứng minh một mô hình tốt hơn; đề cương chọn UCI vì khả năng kiểm chứng và quy mô phù hợp, không vì dữ liệu này đại diện cho mọi trường đại học.

Nhãn đích và đối tượng dự báo

P1 và phân tích chính của P3 giữ ba lớp, qua đó phân biệt sinh viên chưa tốt nghiệp đúng hạn với sinh viên bỏ học. P2 gộp Enrolled vào nhóm còn lại; thí nghiệm nhị phân bổ sung của P3 lại gộp Enrolled với Dropout thành Not Graduate. P4 dùng quy tắc không đăng ký môn hai năm, còn P5 dựa trên trạng thái cuối trong hồ sơ. Những cách gộp này trả lời các câu hỏi khác nhau. Nhóm giữ ba lớp làm chính và chỉ dùng Dropout so với hai lớp còn lại như phân tích bổ sung, không gọi nhóm còn lại là "chắc chắn tốt nghiệp".

Thời điểm thông tin

P3 và P4 trực tiếp so sánh nhiều mốc, phù hợp nhất với câu hỏi về giá trị bổ sung của thông tin học kỳ một. P1 chứa đồng thời thông tin nhập học, học kỳ một và học kỳ hai; P2 dùng 36 đặc trưng nên không tách được giá trị riêng của thời điểm T1. P5 tổng hợp nhiều biến của học kỳ cuối trước tốt nghiệp hoặc bỏ học, nên điểm số cao không chứng minh khả năng cảnh báo sớm. Nhóm sẽ lập danh sách biến được phép cho từng mốc và không sử dụng học kỳ hai hoặc biến có thời điểm cập nhật không rõ trong phân tích chính.

Tiền xử lý và mất cân bằng lớp

P1 chỉ ra sự mất cân bằng và tương quan giữa các biến. P2 nhân đôi lớp Dropout trước bước chia dữ liệu theo trình bày của bài, tạo rủi ro giao nhau giữa các tập. P3 nêu SMOTE được áp dụng trên tập huấn luyện, nhưng nhóm vẫn cần đặt mọi thao tác học từ dữ liệu bên trong từng fold khi tự triển khai. P4 có các bước điền thiếu, gom môn theo độ khó và xử lý LMS phức tạp hơn, không thể chuyển trực tiếp sang UCI. P5 cho thấy oversampling không mặc nhiên cải thiện F1 và có đoạn mã chuẩn hóa trước chia tập. Nhóm ưu tiên pipeline và trọng số lớp, không nhân bản dữ liệu trước khi tách tập.

Lựa chọn mô hình

RF và các phương pháp tổ hợp cây xuất hiện trong nhiều bài, nhưng mô hình tốt nhất phụ thuộc nhiệm vụ. P2 ưu tiên RF trong thiết kế của mình; P3 cho thấy BRF có thể

có F1 Dropout tốt hơn dù một mô hình khác đạt global F1 cao hơn; P4 ghi nhận khác biệt giữa XGBoost và NN theo chỉ số; P5 cho LightGBM tốt nhất ở bảng thí nghiệm chính. Nhóm chọn LR làm đối chứng tuyến tính dễ giải thích và RF làm đối chứng phi tuyến quen thuộc. Đây là lựa chọn để trả lời câu hỏi T0–T1 trong phạm vi khả thi, không phải tuyên bố hai mô hình đó tốt hơn mọi phương pháp còn lại.

Giao thức và chỉ số đánh giá

P3 mô tả chia tập phân tầng, kiểm định chéo và lặp seed rõ hơn P1, vốn là bài mô tả dữ liệu. P2 và P5 trình bày chia 80/20; P4 cũng chia 80/20 và dùng GridSearch cho XGBoost. Chỉ số giữa các bài không đồng nhất: accuracy của P2, global F1 của P3, AUC và recall của P4, F1 lớp dương của P5 không thể đổi qua lại. Đề cương quy định macro-F1 là chỉ số chọn mô hình, kèm precision, recall, F1 từng lớp, balanced accuracy và ma trận nhầm lẫn; tập kiểm tra chỉ dùng sau khi đã chốt lựa chọn.

Kết quả và mức độ tin cậy của phép so sánh

Các kết quả của P3 và phân nhóm khoa học máy tính trong P4 gợi ý lợi ích của thông tin học tập xuất hiện sau nhập học. Tuy nhiên, P3 thay đổi thành phần mẫu ở các mốc, còn P4 cho thấy xu hướng khác nhau giữa các ngành. Accuracy 0,9133 của P2 và 0,955 của P5 không phải mốc cạnh tranh trực tiếp với bài toán ba lớp của nhóm. So sánh có ý nghĩa nhất trong đề cương là chênh lệch T1 trừ T0 trên cùng tập kiểm tra và cùng loại mô hình; cần báo cáo cả độ bất định thay vì chỉ chọn một lần chia có kết quả đẹp.

Ưu điểm và hạn chế có thể kế thừa

Nhóm kế thừa mô tả dữ liệu của P1, cách đối chiếu mô hình của P2, tư duy dự báo theo giai đoạn của P3, đánh giá vai trò nhóm thông tin của P4 và việc cân nhắc precision–recall của P5. Những điểm phải kiểm soát gồm thay đổi nhãn, dữ liệu tương lai, xử lý trước chia tập và khả năng tái lập. Không bài nào trong bộ tổng quan đủ để suy ra hiệu quả triển khai ở Việt Nam hoặc tác động làm giảm tỷ lệ bỏ học. Muốn có kết luận đó cần dữ liệu phù hợp và nghiên cứu can thiệp riêng.

2.5 Vấn đề được chọn và hướng đề xuất

Từ tổng quan, nhóm chọn một vấn đề vừa sức: đo giá trị bổ sung của nhóm thông tin học kỳ một trong một giao thức thống nhất. P3 đã có kết quả gần với câu hỏi này, nên đề tài được định vị là kiểm chứng và làm rõ quy trình trên bản UCI công khai. Khác biệt dự kiến nằm ở danh sách biến T0–T1 công khai, giữ nguyên tập mẫu giữa hai cấu hình, không học tiền xử lý từ tập kiểm tra và báo cáo hiệu quả từng lớp cùng chênh lệch ghép cặp.

Việc giữ cùng tập mẫu giúp tách ảnh hưởng của thay đổi tập biến khỏi thay đổi thành phần mẫu, nhưng không khắc phục việc thiếu ngày bỏ học. Vì vậy, nhóm không

tuyên bố giao thức này ưu việt hơn thiết kế vận hành của P3; hai thiết kế phục vụ mục tiêu khác nhau. Nếu giảng viên yêu cầu một nghiên cứu cảnh báo sớm thực sự theo thời gian, cần bổ sung dữ liệu có mốc sự kiện trước khi mở rộng kết luận.

3 Phương pháp đề xuất

3.1 Mục tiêu nghiên cứu

Mục tiêu tổng quát là đánh giá liệu thông tin học kỳ một có đem lại giá trị dự báo bổ sung trên UCI 697 trong điều kiện so sánh công bằng. Các mục tiêu cụ thể gồm xây dựng hai tập biến có lý do lựa chọn; huấn luyện LR và RF bằng quy trình tránh rò rỉ giữa các tập; so sánh T0–T1 bằng chỉ số tổng thể và từng lớp; phân tích lỗi; và cung cấp tài liệu để người khác chạy lại. Thành công của đề tài được xác định bằng việc trả lời có căn cứ các câu hỏi này, không bằng một mức accuracy đặt trước.

3.2 Dữ liệu và biến nghiên cứu

Tệp data.csv hiện lưu từ UCI 697 có 4.424 dòng và 37 cột, gồm 36 biến đầu vào và Target. Tệp đã kiểm tra không có giá trị trống hoặc dòng trùng hoàn toàn. Số mẫu các lớp khớp P1, nhưng P1 mô tả 34 biến đầu vào và một nhãn. Hai cột điểm bằng cấp trước và điểm nhập học có trong bản UCI đang dùng; không vì số lớp giống nhau mà khẳng định mọi giá trị trùng bản trong bài báo. Nhóm sẽ lưu checksum, từ điển biến và phiên bản dữ liệu cùng kết quả [1], [6].

Bảng 3 Danh sách biến cho hai cấu hình

Nhóm biến	**Các biến và nguyên tắc sử dụng**
T0 8 biến	Application mode; Application order; Course; Daytime/evening attendance; Previous qualification; Previous qualification (grade); Admission grade; Age at enrollment.
T1 14 biến	Toàn bộ T0 cộng sáu cột Curricular units 1st sem: (credited), (enrolled), (evaluations), (approved), (grade), (without evaluations).
Không dùng trong phân tích chính	Mọi cột học kỳ hai; Target trong đầu vào; Debtor, Tuition fees up to date, Scholarship holder do thời điểm cập nhật cần làm rõ; các biến còn lại ngoài danh sách để giữ phạm vi đối chứng thống nhất.

T0 có tám biến, T1 có mười bốn biến trước mã hóa. Các tên cột tiếng Anh được giữ trong mã nguồn để tránh nhầm nghĩa. Những cột mã hóa như Course và Application mode được xử lý theo bản chất phân loại, không coi khoảng cách giữa các mã số là khoảng cách có ý nghĩa. Số 0 trong biến học phần hoặc điểm không tự động được xem là thiếu; cần đọc mô tả dữ liệu trước khi xử lý. Target chỉ dùng làm nhãn, không làm biến đầu vào hoặc tiêu chí chọn biến trên toàn bộ dữ liệu.

3.3 Thiết kế so sánh và chia dữ liệu

Thiết kế chính gồm bốn cấu hình: LR–T0, LR–T1, RF–T0 và RF–T1, cộng một mô hình nền luôn chọn lớp phổ biến nhất. Chỉ số dòng được tạo một lần trước khi mã hóa và dùng chung cho mọi cấu hình. Dữ liệu được chia phân tầng thành tập huấn luyện 60%, tập xác thực 20% và tập kiểm tra 20%, với seed 42; số dòng thực tế sau làm tròn được lưu lại. Đây là tỷ lệ thiết kế thực nghiệm, không phải tỷ lệ chính xác kỳ vọng.

Trên tập huấn luyện, nhóm dùng kiểm định chéo phân tầng năm phần để chọn siêu tham số theo macro-F1. Trong mỗi fold, bộ mã hóa, bộ chuẩn hóa và mô hình chỉ được fit bằng phần huấn luyện của fold. Sau đó, mô hình với siêu tham số đã chọn được fit lại trên toàn bộ tập huấn luyện; tập xác thực dùng để so sánh cấu hình và chốt các quyết định bổ sung. Nhóm giữ nguyên mô hình đã fit để đánh giá cuối trên tập kiểm tra, không chọn lại tham số từ kết quả kiểm tra.

Mọi cấu hình chính được báo cáo, kể cả cấu hình có kết quả thấp. Các phép chia bổ sung để khảo sát độ ổn định, nếu thực hiện, phải chốt seed trước khi xem kết quả và được ghi là phân tích bổ sung. Không diễn giải việc chia ngẫu nhiên là đánh giá theo khóa tuyển sinh hoặc đánh giá tương lai, vì bản dữ liệu đang dùng không cung cấp đầy đủ trường để xây dựng giao thức đó.

3.4 Tiền xử lý và mô hình

Quy trình dự kiến là kiểm tra schema, khóa danh sách biến, chia dòng dữ liệu, fit pipeline trên tập huấn luyện, chọn tham số bằng kiểm định chéo, chốt cấu hình trên tập xác thực và cuối cùng đánh giá tập kiểm tra. Với biến phân loại, dùng one-hot encoding có xử lý giá trị chưa gặp. Với LR, các biến định lượng được chuẩn hóa từ thống kê tập huấn luyện; RF không cần bước chuẩn hóa tương tự. Nếu một phiên bản dữ liệu có thiếu giá trị, quy tắc điền phải được công bố và bộ điền cũng chỉ fit trong fold huấn luyện.

Nhóm dùng class_weight như một lựa chọn trong tìm siêu tham số, so sánh với không dùng trọng số. Không nhân đôi dữ liệu trước chia tập và không áp dụng SMOTE trên tập xác thực hoặc kiểm tra. Phương án chính chưa dùng SMOTE vì dữ liệu có nhiều mã phân loại và mục tiêu là đánh giá thông tin T0–T1; việc bổ sung SMOTE sẽ đòi hỏi thiết kế riêng để tránh tạo các giá trị mã không hợp lệ.

Bảng 4 Mô hình và cấu hình tìm kiếm

Cấu hình	Không gian tham số dự kiến	Vai trò
Mô hình nền	Luôn dự báo lớp phổ biến nhất từ tập huấn luyện.	Mốc kiểm tra tối thiểu; không sử dụng nhãn kiểm tra để chọn lớp.
Logistic Regression	C: 0,1; 1; 10. class_weight: không dùng hoặc balanced. max_iter khởi đầu 2.000.	Đối chứng tuyến tính, chuẩn hóa biến định lượng trong pipeline.
Random Forest	200 cây. max_depth: 6 hoặc không giới hạn. min_samples_leaf: 2 hoặc 5. class_weight: không dùng hoặc balanced.	Đối chứng phi tuyến; cùng lưới và seed cho T0–T1.

Mỗi mô hình sử dụng cùng phạm vi tìm tham số ở T0 và T1. Nhóm ghi phiên bản Python, pandas, scikit-learn, seed, danh sách biến và tham số được chọn trong nhật ký chạy. Nếu LR chưa hội tụ, nhóm kiểm tra chuẩn hóa và tăng giới hạn số vòng lặp theo một quy tắc áp dụng đồng thời cho cả hai cấu hình, không sửa riêng cấu hình để làm đẹp kết quả. Hiện bảng trên là cấu hình dự kiến, chưa có kết quả chạy thử để khẳng định thời gian xử lý.

3.5 Tiêu chí đánh giá

Macro-F1 là trung bình không trọng số của F1 ba lớp và là chỉ số chính; cách này không để lớp đông nhất tự quyết định toàn bộ điểm số. Với mỗi lớp, precision phản ánh tỷ lệ dự báo đúng trong những mẫu được gán vào lớp đó, recall phản ánh tỷ lệ nhận diện được trong các mẫu thực sự thuộc lớp, còn F1 kết hợp hai yếu tố. Nhóm đặc biệt xem precision, recall và F1 của Dropout, đồng thời giữ báo cáo của Enrolled và Graduate.

Balanced accuracy là trung bình recall của các lớp. Accuracy được báo cáo như thông tin bổ sung, cùng số lượng mẫu trong từng lớp và ma trận nhầm lẫn có nhãn trục rõ ràng. Nếu một cấu hình không dự báo được mẫu nào của một lớp, nhóm công bố tình trạng đó và quy ước xử lý phép chia cho 0 trong phần mềm; không bỏ lớp khỏi trung bình để nâng điểm số.

Giá trị bổ sung được đo bằng chênh lệch macro-F1 của T1 so với T0 cho từng loại mô hình trên cùng tập kiểm tra; tương tự với recall và F1 Dropout. Dự kiến dùng bootstrap ghép cặp phân tầng 1.000 lần, lấy mẫu lại chỉ số kiểm tra và dùng cùng chỉ số cho hai cấu hình, để tạo khoảng tin cậy percentile 95%. Khoảng này phản ánh biến động do tập kiểm tra đối với các mô hình đã fit, không bao gồm toàn bộ bất định do huấn luyện hoặc chuyển sang một trường khác. Nếu khoảng chênh lệch chứa 0, nhóm chỉ kết luận chưa có bằng chứng rõ về cải thiện trong thiết kế này.

Phân tích nhị phân bổ sung, nếu thực hiện, gộp Enrolled và Graduate thành "không mang nhãn Dropout ở thời điểm gắn nhãn", dùng cùng cách chia dòng và báo cáo

tách biệt. Kết quả nhị phân không thay thế kết quả ba lớp. Nhóm không đặt mục tiêu bắt buộc accuracy trên 90%, vì chỉ số đó không đồng nghĩa phát hiện tốt sinh viên bỏ học và chưa có thực nghiệm riêng để cam kết.

3.6 Phân tích lỗi và giới hạn diễn giải

Nhóm dự kiến đối chiếu các mẫu Dropout bị bỏ sót, các cảnh báo sai và sự nhầm lẫn với Enrolled. Permutation importance trên tập xác thực sẽ hỗ trợ khảo sát vai trò nhóm biến học kỳ một; các biến tương quan có thể chia sẻ thông tin nên không diễn giải mức quan trọng thấp là biến hoàn toàn vô ích. Mức quan trọng hoặc tương quan chỉ mô tả quan hệ dự báo, không chứng minh nguyên nhân gây bỏ học.

Các rủi ro chính gồm thiếu mốc bỏ học, thiếu thông tin đầy đủ về thời điểm cập nhật một số biến, khác biệt giữa các khóa và ngành, cùng hạn chế chuyển giao từ dữ liệu Bồ Đào Nha sang Việt Nam. Không tái nhận diện cá nhân và không dùng kết quả phân loại để tự động hạn chế quyền học tập. Trong phạm vi đề cương, đầu ra là bằng chứng nghiên cứu và mã nguồn tái lập, chưa phải hệ thống ra quyết định cho nhà trường.

4 Kế hoạch thực hiện

4.1 Các giai đoạn và sản phẩm kiểm tra

Kế hoạch dự kiến kéo dài 12 tuần tính từ thời điểm bắt đầu triển khai được thống nhất trong học phần. Các tuần dưới đây là mốc tương đối, không phải hạn nộp do giảng viên công bố. Phần tải và tổng hợp năm bài báo đã được chuẩn bị trong báo cáo; các bước thực nghiệm vẫn thuộc kế hoạch.

Bảng 5 Tiến độ dự kiến

Tuần	Công việc	Sản phẩm và điều kiện kiểm tra
1–2	Đối chiếu toàn văn, hoàn thiện bảng và nhận xét theo tiêu chí.	Năm PDF, sổ trích xuất, mỗi số liệu có trang/bảng nguồn.
3	Khóa câu hỏi, nhãn, danh sách biến và protocol.	Từ điển T0–T1; cách chia tập và chỉ số được chốt trước thực nghiệm.
4	Kiểm tra dữ liệu, tạo chỉ số dòng, chia tập và pipeline.	Schema, checksum; các tập không giao nhau; fit tiền xử lý đúng phạm vi.
5–7	Huấn luyện mô hình nền và bốn cấu hình; chọn tham số bằng CV.	Nhật ký từng cấu hình, tham số và kết quả xác thực.
8–9	Đánh giá kiểm tra sau khi chốt; so sánh ghép cặp, phân tích lỗi.	Bảng chỉ số từng lớp, ma trận, khoảng chênh lệch; không chọn lại bằng test.
10	Khảo sát độ ổn định hoặc nhị phân nếu còn thời gian.	Kết quả bổ sung tách biệt, có ghi phạm vi và hạn chế.

Tuần	Công việc	Sản phẩm và điều kiện kiểm tra
11–12	Viết kết quả, rà nguồn và mã, chuẩn bị trình bày.	Báo cáo hoàn chỉnh, hướng dẫn chạy lại, kiểm tra chéo nội dung.

Sau tuần 3, nhóm phải chốt được danh sách biến và cách đánh giá trước khi huấn luyện. Sau tuần 7, nhóm phải có các cấu hình được chọn mà chưa dựa vào điểm kiểm tra. Nếu phát hiện sai quy trình hoặc trùng dòng giữa các tập, nhóm sửa lỗi và chạy lại các cấu hình bị ảnh hưởng, ghi lý do trong nhật ký; không chỉ thay một con số trong báo cáo.

4.2 Phân công dự kiến

Bảng 6 Phân công nhóm 4 lớp DCT123C4

Thành viên	Nhiệm vụ dự kiến
Lý Đức Huy 3123411114	Theo dõi tài liệu và DOI; kiểm tra nguồn của bảng tổng quan.
Nguyễn Quốc Huy 3123411120	Tổng hợp đề cương; quản lý phiên bản và tích hợp kết quả.
Trần Nam Khang 3123411144	Kiểm tra dữ liệu, từ điển biến và cách chia tập.
Võ Quốc Khánh 3123411151	Xây dựng pipeline, huấn luyện LR và RF theo protocol đã chốt.
Lâm Trác Đạt 3123411064	Tính chỉ số, kiểm tra bảng và hình, phân tích lỗi, phối hợp trình bày.

Đây là phân công đề xuất để triển khai, không phải xác nhận các thành viên đã thực hiện xong. Mỗi bảng số liệu phải được ít nhất một thành viên khác đối chiếu với nguồn hoặc tệp kết quả. Khi báo cáo, cả nhóm cần giải thích được khác biệt giữa kết quả của tác giả và kết quả của nhóm, giữa T0 và T1, cũng như lý do không so sánh trực tiếp accuracy giữa các bài.

4.3 Nguồn lực và phương án khi gặp khó khăn

Nguồn lực chính là máy tính cá nhân, dữ liệu công khai và công cụ Python. Với quy mô vài nghìn dòng, lựa chọn LR và RF giúp giới hạn độ phức tạp; thời gian thực tế vẫn cần đo ở lần chạy thử. Không phụ thuộc thuê GPU, truy cập hồ sơ nội bộ hoặc trả phí để lấy toàn văn các bài đã chọn. Chi phí in ấn chỉ phát sinh theo yêu cầu nộp của học phần và chưa lập dự toán cứng khi chưa có thông tin.

Nếu thời gian huấn luyện vượt khả năng máy, nhóm thu hẹp lưới tham số theo một quy tắc công bố trước và áp dụng cho cả T0 lẫn T1. Nếu thông tin về thời điểm của một

biến không rõ, nhóm loại khỏi phân tích chính và nêu lý do. Nếu T1 không cải thiện, nhóm kiểm tra mã và độ bất định rồi báo cáo trung thực, không chuyển mục tiêu sang tìm một mô hình đạt điểm cao bằng mọi cách.

5 Kết quả dự kiến

5.1 Sản phẩm đầu ra

Sản phẩm dự kiến gồm báo cáo tổng quan năm bài với bảng so sánh và nhận xét theo tiêu chí; bộ dữ liệu kèm nguồn, checksum và từ điển biến; mã tạo T0–T1 và chia tập; pipeline huấn luyện; bảng kết quả của các cấu hình; ma trận nhầm lẫn; biểu đồ chênh lệch hiệu năng có khoảng tin cậy; cùng hướng dẫn chạy lại. Các tệp kết quả phải ghi được mô hình, nhóm biến, seed, số mẫu, chỉ số và tham số tương ứng.

Phần tổng quan và bản đề cương đã được biên soạn trong tài liệu này. Những bảng và biểu đồ hiệu năng nêu trên là sản phẩm của giai đoạn thực nghiệm sắp tới; báo cáo không điền sẵn các giá trị dự kiến vào ô kết quả. Giá trị khoa học trong phạm vi học phần là trả lời được thông tin học kỳ một giúp ích đến đâu dưới một thiết kế minh bạch.

5.2 Kết quả mong đợi và cách kết luận

Từ P3 và P4, nhóm kỳ vọng T1 có thể cung cấp tín hiệu tốt hơn T0, nhất là qua tiến độ hoàn thành học phần. Tuy nhiên, mức cải thiện, mô hình tốt hơn và khả năng phân biệt lớp Enrolled vẫn chưa biết. Nếu T1 cải thiện nhất quán và khoảng chênh lệch hỗ trợ kết luận đó, nhóm sẽ mô tả lợi ích trong giới hạn bộ dữ liệu và giao thức. Nếu cải thiện chỉ xuất hiện ở accuracy hoặc lớp Graduate mà recall Dropout giảm, nhóm sẽ không gọi đó là cải thiện đồng đều.

Nếu hai mô hình cho kết quả trái chiều, nhóm phân tích cách khai thác quan hệ tuyến tính và phi tuyến, độ bất định và lỗi từng lớp. Nếu chênh lệch không rõ hoặc T1 kém hơn, báo cáo vẫn có giá trị khi xác định điều kiện mà thêm thông tin không đem lại lợi ích như kỳ vọng. Không suy từ kết quả hồi cứu sang kết luận rằng một biện pháp hỗ trợ sẽ làm giảm tỷ lệ bỏ học.

5.3 Tính khả thi và điều kiện hoàn thành

Đề tài có cơ sở khả thi ở việc đã có dữ liệu công khai, đã lưu năm bài toàn văn, có hai mô hình chuẩn và thiết kế so sánh giới hạn. Khối lượng được chia thành các sản phẩm có thể kiểm tra trong kế hoạch 12 tuần. Tuy nhiên, chưa có cơ sở để gán một xác suất thành công cụ thể hoặc cam kết mức chính xác 90%; tính khả thi ở đây được đánh giá bằng khả năng tiếp cận dữ liệu, triển khai quy trình và trả lời câu hỏi nghiên cứu.

Điều kiện hoàn thành gồm truy được nguồn của các số liệu tổng quan; chạy lại được quy trình từ dữ liệu gốc; chứng minh các tập không giao nhau; có đầy đủ kết quả bốn cấu hình và mô hình nền; phân tích sai số và hạn chế; và giữ nguyên kết quả kể cả

khi không đạt kỳ vọng. Để triển khai thực tế, cần bổ sung dữ liệu có thời gian sự kiện, kiểm định trên khóa mới và sự tham gia của đơn vị quản lý giáo dục; các bước đó nằm ngoài phạm vi đề cương hiện tại.

Tài liệu tham khảo

[1] V. Realinho, J. Machado, L. Baptista và M. V. Martins, "Predicting Student Dropout and Academic Success," Data, tập 7, số 11, bài 146, 2022. DOI: https://doi.org/10.3390/data7110146.

[2] Nông Thị Hoa, "Ứng dụng các mô hình học máy vào dự đoán tình trạng bỏ học của sinh viên," TNU Journal of Science and Technology, tập 230, số 07, tr. 120–125, 2025. DOI: https://doi.org/10.34238/tnu-jst.12201.

[3] M. V. Martins, L. Baptista, J. Machado và V. Realinho, "Multi-Class Phased Prediction of Academic Performance and Dropout in Higher Education," Applied Sciences, tập 13, số 8, bài 4702, 2023. DOI: https://doi.org/10.3390/app13084702.

[4] O. Goren, L. Cohen và A. Rubinstein, "Early Prediction of Student Dropout in Higher Education using Machine Learning Models," Proceedings of the 17th International Conference on Educational Data Mining, tr. 349–359, 2024. DOI: https://doi.org/10.5281/zenodo.12729834.

[5] C. H. Cho, Y. W. Yu và H. G. Kim, "A Study on Dropout Prediction for University Students Using Machine Learning," Applied Sciences, tập 13, số 21, bài 12004, 2023. DOI: https://doi.org/10.3390/app132112004.

[6] V. Realinho, M. V. Martins, J. Machado và L. Baptista, Predict Students' Dropout and Academic Success, UCI Machine Learning Repository, bộ dữ liệu 697, 2021. DOI: https://doi.org/10.24432/C5MC89. Nguồn dữ liệu bổ trợ, không tính là bài báo trong bộ năm bài.

Phụ lục đối chiếu nguồn

Các tệp P1–P5 được lưu trong TaiLieuNguon/TongQuan_2026-11-06. Số trang dưới đây là trang PDF; đọc cùng tên bảng hoặc mục để tránh nhầm với số trang in trên bài. Bản tải gốc của P2 được giữ riêng; bản đọc đã sửa phần bao tệp PDF bị lỗi, không thay nội dung bài.

Bảng 7 Sổ đối chiếu các dữ kiện chính

Nguồn	Vị trí trong PDF	Nội dung cần đối chiếu
P1	Tr. 3–4, 7, 10–11	34 biến + nhãn; quy trình dữ liệu; 4.424 hồ sơ và số lượng lớp; permutation importance, không có bảng benchmark accuracy.
P2	Tr. 3, mục 2.2; tr. 4, mục 3 và Bảng 2; tr. 5, Bảng 5	Gộp nhãn và nhân đôi Dropout; chia 80/20; 1.169 mẫu ghi trong bài; RF: 773 + 60 + 92 + 829 = 1.754; accuracy 0,9133.
P3	Tr. 4–7, mục 4; tr. 8, Bảng 3–5; tr. 9, Bảng 7	4.433 hồ sơ gốc; khác tập mẫu theo mốc; giao thức 90/10 và CV; S1 Test F1 0,745 ± 0,014; F1 Dropout BRF 0,728 ± 0,026.
P4	Tr. 3, mục 2–3; tr. 5, Bảng 2; tr. 10, Phụ lục A–D	8.267 sinh viên; định nghĩa nhãn; AUC 0,63 và 0,86 của XGBoost không LMS ở ngành CS; preprocessing và tham số.
P5	Tr. 5–8, mục 3; tr. 10–11, Bảng 8; tr. 13, Bảng 10	Tổng hợp bản ghi; StandardScaler trước chia trong đoạn mã; LightGBM F1 0,840; RF 0,827 và 0,830; thiếu kết quả LightGBM+SMOTE.
UCI [6]	TaiLieuNguon/data.csv và trang UCI 697	Tệp thực nghiệm: 4.424 dòng, 36 biến và Target. Đây là nguồn dữ liệu, không phải bài báo thứ sáu.

Những con số 0,9133; 0,745; 0,728; 0,63; 0,86 và 0,840 trong tổng quan là kết quả được tác giả báo cáo. Phép cộng ma trận P2 để kiểm tra số mẫu là phép đối chiếu của nhóm. Nhận xét về rò rỉ, thời điểm thông tin và phạm vi suy rộng là đánh giá phương pháp của nhóm, không phải kết luận nguyên văn của các tác giả.