ỦY BAN NHÂN DÂN TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN

BÁO CÁO CUỐI KỲ
PHƯƠNG PHÁP NGHIÊN CỨU KHOA HỌC TRONG CÔNG NGHỆ THÔNG TIN

ĐÁNH GIÁ GIÁ TRỊ BỔ SUNG CỦA THÔNG TIN HỌC KỲ THỨ NHẤT TRONG DỰ BÁO TÌNH TRẠNG HỌC TẬP CỦA SINH VIÊN: NGHIÊN CỨU TRÊN BỘ DỮ LIỆU UCI

NHÓM 4 – LỚP DCT123C4
Lý Đức Huy – 3123411114
Nguyễn Quốc Huy – 3123411120
Trần Nam Khang – 3123411144
Võ Quốc Khánh – 3123411151
Lâm Trác Đạt – 3123411064

NGÀNH: CÔNG NGHỆ THÔNG TIN
TRÌNH ĐỘ ĐÀO TẠO: ĐẠI HỌC

TP. HỒ CHÍ MINH, THÁNG 11 NĂM 2026

MỤC LỤC

1. Tên đề tài 2
2. Lĩnh vực nghiên cứu 2
3. Thời gian thực hiện 2
4. Chủ nhiệm đề tài 2
5. Các thành viên tham gia thực hiện đề tài 3
6. Mô tả năng lực nghiên cứu chủ nhiệm và các thành viên 3
7. Cán bộ hướng dẫn sinh viên thực hiện đề tài 3
8. Tình hình nghiên cứu liên quan đến đề tài 4
9. Tính cấp thiết của đề tài 10
10. Mục tiêu đề tài 11
11. Đối tượng và phạm vi nghiên cứu 12
12. Phương pháp nghiên cứu 13
13. Nội dung nghiên cứu và tiến độ thực hiện 16
14. Sản phẩm khoa học và công nghệ của đề tài 17
15. Khả năng ứng dụng và phát triển của đề tài 18
16. Kinh phí thực hiện đề tài NCKH của sinh viên 19
Tài liệu tham khảo 21

ỦY BAN NHÂN DÂN
THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN

CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM
Độc lập – Tự do – Hạnh phúc

Thành phố Hồ Chí Minh, ngày tháng năm 20…

THUYẾT MINH ĐỀ TÀI NGHIÊN CỨU KHOA HỌC CẤP TRƯỜNG CỦA SINH VIÊN

1. Tên đề tài

Đánh giá giá trị bổ sung của thông tin học kỳ thứ nhất trong dự báo nguy cơ bỏ học của sinh viên trên dữ liệu UCI 697.

2. Lĩnh vực nghiên cứu

Khoa học Tự nhiên	☐	Khoa học Kỹ thuật và Công nghệ	☒
Khoa học Y, dược	☐	Khoa học Nông nghiệp	☐
Khoa học Xã hội	☐	Khoa học Nhân văn	☐

Loại đề tài: ☐ A1 ☐ B1 ☐ B2 ☐ C (chờ xác nhận).

3. Thời gian thực hiện

Dự kiến 3 tháng (12 tuần), tính từ thời điểm bắt đầu do nhóm và cán bộ hướng dẫn thống nhất.

4. Chủ nhiệm đề tài

Họ và tên: MSSV:

Lớp: DCT123C4. Chương trình đào tạo: Đại học, ngành Công nghệ thông tin.

Khoa: Công nghệ thông tin. Điện thoại: . Email: .

5. Các thành viên tham gia thực hiện đề tài

STT	Họ và tên	Đơn vị (MSSV, lớp, CTĐT)	Nội dung nghiên cứu cụ thể được giao	Chữ ký
1	Lý Đức Huy	3123411114 DCT123C4 Đại học – CNTT	Theo dõi tài liệu và DOI; kiểm tra nguồn của bảng tổng quan.	
2	Nguyễn Quốc Huy	3123411120 DCT123C4 Đại học – CNTT	Tổng hợp đề cương; quản lý phiên bản và tích hợp kết quả.	
3	Trần Nam Khang	3123411144 DCT123C4 Đại học – CNTT	Kiểm tra dữ liệu, từ điển biến và cách chia tập.	
4	Võ Quốc Khánh	3123411151 DCT123C4 Đại học – CNTT	Xây dựng pipeline, huấn luyện LR và RF theo protocol đã chốt.	
5	Lâm Trác Đạt	3123411064 DCT123C4 Đại học – CNTT	Tính chỉ số, kiểm tra bảng và hình, phân tích lỗi, phối hợp trình bày.	

6. Mô tả năng lực nghiên cứu chủ nhiệm và các thành viên

Nhóm đã lập bảng đối chiếu năm bài báo từ toàn văn và kiểm tra lại số liệu của bộ UCI 697 trong bài giữa kỳ. Các sản phẩm hiện có gồm mã xử lý dữ liệu, ba hình minh họa và bảng số liệu dùng để kiểm tra lại các hình. Đây là cơ sở để nhóm triển khai các khâu đọc tài liệu, làm sạch dữ liệu và kiểm tra kết quả.

Ở giai đoạn thực nghiệm, thành viên phụ trách dữ liệu dự kiến kiểm tra các tập chia, thành viên phụ trách mô hình lưu cấu hình từng lần huấn luyện và thành viên phụ trách đánh giá đối chiếu các chỉ số với tệp dự đoán. Người điều phối tổng hợp kết quả sau khi một thành viên khác đã kiểm tra.

7. Cán bộ hướng dẫn sinh viên thực hiện đề tài

Họ và tên	số ĐTDĐ	Khoa	Chữ ký
[Điền theo phân công]	[Điền]	[Điền]	

8. Tình hình nghiên cứu liên quan đến đề tài

8.1. Ý tưởng, từ khóa và tiêu chí chọn tài liệu

Ý tưởng được tách thành ba nhóm khái niệm: đối tượng là sinh viên đại học có nguy cơ bỏ học; kỹ thuật là học máy trên dữ liệu dạng bảng; trọng tâm là thời điểm dự báo, thông tin học kỳ một và đánh giá trong điều kiện mất cân bằng lớp. Cách tách này giúp tìm những bài giải quyết cùng vấn đề kỹ thuật thay vì chỉ trùng cụm từ trong tiêu đề.

Nhóm	**Từ khóa hoặc chuỗi truy vấn**
Vấn đề	student dropout prediction; academic success; higher education; dự đoán sinh viên bỏ học
Thời điểm	early prediction; phased prediction; first semester; pre-enrollment data
Kỹ thuật	machine learning; Random Forest; logistic regression; class imbalance; data leakage
Truy vấn kết hợp	"student dropout" AND "higher education" AND "first semester"; "Multi-Class Phased Prediction"; "dropout prediction" AND "oversampling"
Truy vấn tiếng Việt	"dự đoán" "bỏ học" "sinh viên" "học máy"

Nhóm tìm thông tin thư mục và đường dẫn trên trang nhà xuất bản, trang hội nghị và kho lưu trữ; sau đó tải toàn văn PDF về máy trước khi trích xuất, đọc và lập bảng. Các bài [1], [2] đã có trong tài liệu của bản trước; các bài [3]–[5] được bổ sung cho lần tổng quan này. Ngày hoàn tất đợt tìm và đối chiếu là 06/11/2026. Nội dung phân tích không lấy từ đoạn mô tả của kết quả tìm kiếm.

Tiêu chí chọn gồm: có toàn văn; nghiên cứu liên quan đến bỏ học hoặc tình trạng học tập trong giáo dục đại học; có mô tả dữ liệu, phương pháp hoặc cách đánh giá đủ để đối chiếu; và có vai trò rõ trong đề tài. Bài [1] là bài mô tả dữ liệu nền tảng, còn [2]–[5] là các nghiên cứu thực nghiệm. Các trang chỉ giới thiệu dữ liệu, bài không có toàn văn và nghiên cứu chỉ dự đoán điểm một môn không phù hợp với trọng tâm được loại khỏi bộ năm bài. Đây là tổng quan có chủ đích phục vụ đề cương, không phải tổng quan hệ thống bao quát toàn bộ lĩnh vực.

Trong phần sau, P1–P5 lần lượt tương ứng với tài liệu [1]–[5]. Vị trí trang ghi theo thứ tự trang của tệp PDF, bắt đầu từ trang 1. Riêng bài P2, trang PDF 4 tương ứng trang in 123; bài P4 bắt đầu ở trang in 349. Sổ đối chiếu ở phụ lục giúp truy lại các số liệu chính.

8.2. Nghiên cứu trong nước và quốc tế

P1 Bài công bố dữ liệu của Realinho và cộng sự

Realinho và cộng sự [1] mô tả cách kết hợp nguồn tuyển sinh, hồ sơ học tập và dữ liệu kinh tế, làm sạch và xây dựng nhãn cho 4.424 hồ sơ. Bài phân tích mất cân bằng,

tương quan và permutation importance bằng bốn mô hình tổ hợp cây với F1. Đây là nguồn để hiểu dữ liệu, không phải bảng chuẩn accuracy để xếp hạng mô hình. Các biến học kỳ hai trong bài không được chuyển sang kịch bản T1. Đối chiếu: trang 3–4, 7 và 10–11.

P2 Nghiên cứu trong nước của Nông Thị Hoa

Nông Thị Hoa [2] thử NN, RF và SVM trên UCI, gộp Enrolled với Graduate rồi báo cáo RF đạt accuracy 0,9133. Mục 2.2 mô tả nhân đôi Dropout trước chia tập, tạo nguy cơ bản sao có mặt trong cả huấn luyện lẫn kiểm tra. Trang PDF 4 ghi 1.169 mẫu kiểm tra nhưng ma trận RF cộng thành 1.754. Nhóm dùng bài để tham khảo mô hình và kiểm tra phương pháp, không lấy 0,9133 làm chuẩn phải đạt. Nguồn dữ liệu vẫn là nước ngoài.

P3 Nghiên cứu dự báo theo giai đoạn của Martins và cộng sự

Martins và cộng sự [3] sử dụng dữ liệu gốc 4.433 sinh viên, xây dựng S0 lúc nhập học, S1 cuối học kỳ một và S2 cuối học kỳ hai. Bài so sánh năm phương pháp kết hợp học máy và cân bằng lớp, chia 90/10, dùng CV và lặp seed. Tại S1, SVMSMOTE + RF có Test F1 Score 0,745 ± 0,014. Không đổi tên "global F1" thành macro-F1 khi cách lấy trung bình chưa rõ. Việc loại hồ sơ đã bỏ học ở giai đoạn sau làm thay đổi thành phần mẫu, gợi ý nhóm cần tách ảnh hưởng của tập biến khỏi ảnh hưởng của tập mẫu. Đối chiếu: trang 4–9.

P4 Nghiên cứu theo thời điểm và ngành của Goren và cộng sự

Goren, Cohen và Rubinstein [4] nghiên cứu 8.267 sinh viên giai đoạn 2019–2022, kết hợp dữ liệu đầu vào, LMS và kết quả học tập. XGBoost và NN được đánh giá tại nhiều mốc bằng AUC và recall Dropout. Riêng ngành khoa học máy tính, XGBoost không LMS có AUC 0,63 ở Pre-Entry và 0,86 sau kỳ thi B. Lợi ích của LMS phụ thuộc mô hình và thời điểm; kết quả một phân nhóm không đại diện tự động cho toàn bộ mẫu. Đối chiếu: trang 3–7 và phụ lục trang 10.

P5 Nghiên cứu mất cân bằng lớp của Cho và cộng sự

Cho, Yu và Kim [5] tổng hợp khoảng 168.000 bản ghi học kỳ của 20.050 sinh viên, rồi so sánh sáu mô hình. Bảng 8 báo cáo LightGBM đạt accuracy 0,955 và F1 lớp bỏ học 0,840. SMOTE chỉ cải thiện nhẹ F1 của RF; không có kết quả LightGBM + SMOTE do lỗi tương thích. Bài dùng nhiều biến học kỳ cuối và chuẩn hóa toàn bộ X trước chia tập trong đoạn mã, nên không thể xem điểm số là bằng chứng cho cảnh báo ngay lúc nhập học. Đối chiếu: trang 5–8 và 10–15.

8.3. So sánh các công trình theo tiêu chí kỹ thuật

Bảng 8.1 và 8.2 đối chiếu năm công trình. Các số đo được trích từ bài gốc. Nhóm đánh giá ưu điểm và hạn chế trong bối cảnh dữ liệu, định nghĩa nhãn và thời điểm dự báo của từng bài.

Bảng 8.1. Dữ liệu, tiền xử lý, mô hình và cách đánh giá

Bài	Dữ liệu và thời điểm	Tiền xử lý	Mô hình và đánh giá
P1 [1]	4.424 hồ sơ Portalegre. Ba lớp. Biến nhập học và hai học kỳ; 34 biến đầu vào trong bài mô tả.	Ghép nguồn; làm sạch, loại trùng, ẩn danh; phân tích mất cân bằng và tương quan.	RF, XGBoost, LightGBM, CatBoost để khảo sát permutation importance theo F1. Không có giao thức benchmark đủ chi tiết.
P2 [2]	UCI 4.424 hồ sơ, 36 biến. Gộp Graduate và Enrolled. Có thông tin cả học kỳ hai.	Mã hóa nhãn, chuẩn hóa; mô tả nhân đôi Dropout trước chia tập; xem xét đặc trưng quan trọng.	NN, RF, SVM. Chia 80/20 trên dữ liệu đã cân bằng; thử một số cấu hình. Chỉ số chính accuracy.
P3 [3]	4.433 hồ sơ gốc. Ba lớp; S0, S1, S2. Loại hồ sơ đã bỏ học khỏi các giai đoạn sau, làm thay đổi thành phần mẫu.	SMOTE hoặc SVMSMOTE với RF; hoặc cân bằng trong thuật toán. SMOTE được mô tả áp dụng trên tập huấn luyện.	SMOTE+RF, SVMSMOTE+RF, BRF, EE, RB. Chia 90/10 phân tầng; CV 10 phần; lặp 10 seed.
P4 [4]	8.267 sinh viên, 2019–2022; nhiều ngành. Bỏ học: không đăng ký môn 2 năm liên tiếp, chưa hoàn thành chương trình. Nhiều mốc từ 4 tuần.	Điền thiếu; chuẩn hóa theo môn; gom môn bằng k-means; đặc trưng studentship từ LMS. XGBoost dùng SMOTE; NN dùng trọng số loss.	XGBoost và NN; chia ngẫu nhiên 80/20; GridSearch cho XGBoost. AUC, recall Dropout và importance theo nhóm biến.
P5 [5]	20.050 sinh viên; khoảng 168.000 bản ghi học kỳ. Nhị phân, nhiều biến của học kỳ cuối; tổng hợp theo sinh viên.	Làm trơn điểm, chọn biến tương quan, StandardScaler trước chia tập trong đoạn mã; thử SMOTE, ADASYN, Borderline-SMOTE.	LR, DT, RF, SVM, DNN, LightGBM. Chia 80/20; bảng kết quả là trung bình 5 lần. Accuracy, precision, recall, F1.

Bảng 8.2. Kết quả, ưu điểm và hạn chế

Bài	Kết quả tác giả báo cáo	Ưu điểm và hạn chế
P1 [1]	Graduate 2.209; Dropout 1.421; Enrolled 794. Biến học phần đạt và học phí nổi bật. Không lấy accuracy làm mốc.	Ưu: mô tả và công bố dữ liệu. Hạn chế: không có ngày bỏ học; không suy diễn sẵn hiệu năng cảnh báo sớm. Tr. 3–4, 7, 10–11.
P2 [2]	RF accuracy 0,9133. Bài ghi 1.169 mẫu kiểm tra; ma trận RF cộng thành 1.754. Không dùng làm mốc trực tiếp.	Ưu: đối chiếu thuật toán, có tham số và ma trận. Hạn chế: nguy cơ bản sao giữa các tập; số mẫu thiếu nhất quán; nhãn nhị phân. Tr. 3–5.
P3 [3]	S1: SVMSMOTE+RF Test F1 0,745 ± 0,014; BRF F1 Dropout 0,728 ± 0,026. Giữ tên global F1 của bài.	Ưu: so sánh theo giai đoạn, có độ phân tán và điểm từng lớp. Hạn chế: tập mẫu thay đổi; không đồng nhất với CSV UCI hiện dùng. Tr. 4–9.
P4 [4]	Riêng ngành CS, XGBoost không LMS: AUC Pre-Entry 0,63; Exam B 0,86. Lợi ích LMS phụ thuộc mô hình và thời điểm.	Ưu: xem xét thời gian, ngành, nhóm thông tin. Hạn chế: dữ liệu nội bộ; đặc trưng phức tạp; cần làm rõ phạm vi fit các bước tổng hợp khi tái lập. Tr. 3–7, 10.

Bài	Kết quả tác giả báo cáo	Ưu điểm và hạn chế
P5 [5]	LightGBM: accuracy 0,955; F1 Dropout 0,840. RF F1 0,827 → 0,830 khi SMOTE. Không có kết quả LightGBM+SMOTE.	Ưu: khảo sát chỉ số lớp dương và tác động oversampling. Hạn chế: chuẩn hóa trước chia; biến học kỳ cuối không chứng minh dự báo sớm. Tr. 5–8, 10–15.

8.4. Nhận xét theo từng tiêu chí

Dữ liệu và khả năng tái lập

P1 cung cấp cơ sở dữ liệu công khai để nhóm có thể kiểm tra trực tiếp; P2 sử dụng UCI nên thuận lợi đối chiếu. P3 cùng bối cảnh Portalegre nhưng nêu 4.433 hồ sơ gốc và thay đổi tập mẫu theo giai đoạn, vì vậy không thể coi là cùng phiên bản CSV 4.424 dòng. P4 và P5 mở rộng sang các cơ sở khác với dữ liệu nội bộ và cách tổng hợp riêng. Chênh lệch cỡ mẫu không chứng minh một mô hình tốt hơn; đề cương chọn UCI vì khả năng kiểm chứng và quy mô phù hợp, không vì dữ liệu này đại diện cho mọi trường đại học.

Nhãn đích và đối tượng dự báo

P1 và phân tích chính của P3 giữ ba lớp, qua đó phân biệt sinh viên chưa tốt nghiệp đúng hạn với sinh viên bỏ học. P2 gộp Enrolled vào nhóm còn lại; thí nghiệm nhị phân bổ sung của P3 lại gộp Enrolled với Dropout thành Not Graduate. P4 dùng quy tắc không đăng ký môn hai năm, còn P5 dựa trên trạng thái cuối trong hồ sơ. Những cách gộp này trả lời các câu hỏi khác nhau. Nhóm giữ ba lớp làm chính và chỉ dùng Dropout so với hai lớp còn lại như phân tích bổ sung, không gọi nhóm còn lại là "chắc chắn tốt nghiệp".

Thời điểm thông tin

P3 và P4 trực tiếp so sánh nhiều mốc, phù hợp nhất với câu hỏi về giá trị bổ sung của thông tin học kỳ một. P1 chứa đồng thời thông tin nhập học, học kỳ một và học kỳ hai; P2 dùng 36 đặc trưng nên không tách được giá trị riêng của thời điểm T1. P5 tổng hợp nhiều biến của học kỳ cuối trước tốt nghiệp hoặc bỏ học, nên điểm số cao không chứng minh khả năng cảnh báo sớm. Nhóm sẽ lập danh sách biến được phép cho từng mốc và không sử dụng học kỳ hai hoặc biến có thời điểm cập nhật không rõ trong phân tích chính.

Tiền xử lý và mất cân bằng lớp

P1 chỉ ra sự mất cân bằng và tương quan giữa các biến. P2 nhân đôi lớp Dropout trước bước chia dữ liệu theo trình bày của bài, tạo rủi ro giao nhau giữa các tập. P3 nêu SMOTE được áp dụng trên tập huấn luyện, nhưng nhóm vẫn cần đặt mọi thao tác học từ dữ liệu bên trong từng fold khi tự triển khai. P4 có các bước điền thiếu, gom môn theo độ khó và xử lý LMS phức tạp hơn, không thể chuyển trực tiếp sang UCI. P5 cho thấy oversampling không mặc nhiên cải thiện F1 và có đoạn mã chuẩn hóa trước chia tập. Nhóm ưu tiên pipeline và trọng số lớp, không nhân bản dữ liệu trước khi tách tập.

Lựa chọn mô hình

RF và các phương pháp tổ hợp cây xuất hiện trong nhiều bài, nhưng mô hình tốt nhất phụ thuộc nhiệm vụ. P2 ưu tiên RF trong thiết kế của mình; P3 cho thấy BRF có thể có F1 Dropout tốt hơn dù một mô hình khác đạt global F1 cao hơn; P4 ghi nhận khác biệt giữa XGBoost và NN theo chỉ số; P5 cho LightGBM tốt nhất ở bảng thí nghiệm chính. Nhóm chọn LR làm đối chứng tuyến tính dễ giải thích và RF làm đối chứng phi tuyến quen thuộc. Đây là lựa chọn để trả lời câu hỏi T0–T1 trong phạm vi khả thi, không phải tuyên bố hai mô hình đó tốt hơn mọi phương pháp còn lại.

Giao thức và chỉ số đánh giá

P3 mô tả chia tập phân tầng, kiểm định chéo và lặp seed rõ hơn P1, vốn là bài mô tả dữ liệu. P2 và P5 trình bày chia 80/20; P4 cũng chia 80/20 và dùng GridSearch cho XGBoost. Chỉ số giữa các bài không đồng nhất: accuracy của P2, global F1 của P3, AUC và recall của P4, F1 lớp dương của P5 không thể đổi qua lại. Đề cương quy định macro-F1 là chỉ số chọn mô hình, kèm precision, recall, F1 từng lớp, balanced accuracy và ma trận nhầm lẫn; tập kiểm tra chỉ dùng sau khi đã chốt lựa chọn.

Kết quả và mức độ tin cậy của phép so sánh

Các kết quả của P3 và phân nhóm khoa học máy tính trong P4 gợi ý lợi ích của thông tin học tập xuất hiện sau nhập học. Tuy nhiên, P3 thay đổi thành phần mẫu ở các mốc, còn P4 cho thấy xu hướng khác nhau giữa các ngành. Accuracy 0,9133 của P2 và 0,955 của P5 không phải mốc cạnh tranh trực tiếp với bài toán ba lớp của nhóm. So sánh có ý nghĩa nhất trong đề cương là chênh lệch T1 trừ T0 trên cùng tập kiểm tra và cùng loại mô hình; cần báo cáo cả độ bất định thay vì chỉ chọn một lần chia có kết quả đẹp.

Ưu điểm và hạn chế có thể kế thừa

Nhóm kế thừa mô tả dữ liệu của P1, cách đối chiếu mô hình của P2, tư duy dự báo theo giai đoạn của P3, đánh giá vai trò nhóm thông tin của P4 và việc cân nhắc precision–recall của P5. Những điểm phải kiểm soát gồm thay đổi nhãn, dữ liệu tương lai, xử lý trước chia tập và khả năng tái lập. Không bài nào trong bộ tổng quan đủ để suy ra hiệu quả triển khai ở Việt Nam hoặc tác động làm giảm tỷ lệ bỏ học. Muốn có kết luận đó cần dữ liệu phù hợp và nghiên cứu can thiệp riêng.

8.5. Khoảng trống và hướng nghiên cứu

Từ tổng quan, nhóm chọn một vấn đề vừa sức: đo giá trị bổ sung của nhóm thông tin học kỳ một trong một giao thức thống nhất. P3 đã có kết quả gần với câu hỏi này, nên đề tài được định vị là kiểm chứng và làm rõ quy trình trên bản UCI công khai. Khác biệt dự kiến nằm ở danh sách biến T0–T1 công khai, giữ nguyên tập mẫu giữa hai cấu hình, không học tiền xử lý từ tập kiểm tra và báo cáo hiệu quả từng lớp cùng chênh lệch ghép cặp.

Việc giữ cùng tập mẫu giúp tách ảnh hưởng của thay đổi tập biến khỏi thay đổi thành phần mẫu, nhưng không khắc phục việc thiếu ngày bỏ học. Vì vậy, nhóm không tuyên bố giao thức này ưu việt hơn thiết kế vận hành của P3; hai thiết kế phục vụ mục tiêu khác nhau. Nếu giảng viên yêu cầu một nghiên cứu cảnh báo sớm thực sự theo thời gian, cần bổ sung dữ liệu có mốc sự kiện trước khi mở rộng kết luận.

9. Tính cấp thiết của đề tài

Dự báo nguy cơ bỏ học có thể cung cấp thông tin để nhà trường cân nhắc hỗ trợ sinh viên. Tuy nhiên, một mô hình dự báo tốt phải được đánh giá theo thông tin thực sự có tại thời điểm sử dụng. Điểm học kỳ hai có thể giúp nhận diện sinh viên bỏ học trong dữ liệu lịch sử, nhưng không thể dùng để đưa ra dự báo ngay lúc nhập học. Vì vậy, thời điểm quan sát và giá trị bổ sung của từng nhóm thông tin là vấn đề trung tâm của đề tài.

Các công trình đã đọc cho thấy kết quả học tập có giá trị dự báo, nhưng cách định nghĩa bỏ học, lựa chọn thời điểm và đánh giá khác nhau đáng kể. Martins và cộng sự đã nghiên cứu dự báo theo giai đoạn [3]; do đó, nhóm không coi việc bổ sung điểm học kỳ một là một ý tưởng hoàn toàn mới. Đóng góp dự kiến là một thực nghiệm kiểm chứng trong phạm vi học phần, với cùng tập sinh viên, cùng cách chia tập và quy trình xử lý có thể kiểm tra lại.

Nếu các biến chỉ có sau khi kết thúc năm học được đưa vào mô hình tại thời điểm nhập học, kết quả đánh giá sẽ phóng đại lượng thông tin mà nhà trường thực sự có. Việc so sánh trên cùng tập sinh viên giúp định lượng phần giá trị tăng thêm khi có kết quả học kỳ một, đồng thời cho thấy lớp nào vẫn khó nhận diện.

10. Mục tiêu đề tài

Mục tiêu tổng quát là đánh giá liệu thông tin học kỳ một có đem lại giá trị dự báo bổ sung trên UCI 697 trong điều kiện so sánh công bằng. Các mục tiêu cụ thể gồm xây dựng hai tập biến có lý do lựa chọn; huấn luyện LR và RF bằng quy trình tránh rò rỉ giữa các tập; so sánh T0–T1 bằng chỉ số tổng thể và từng lớp; phân tích lỗi; và cung cấp tài liệu để người khác chạy lại. Thành công của đề tài được xác định bằng việc trả lời có căn cứ các câu hỏi này, không bằng một mức accuracy đặt trước.

10.1. Câu hỏi và giả thuyết nghiên cứu

Câu hỏi chính là: khi giữ nguyên tập sinh viên và cách đánh giá, bổ sung thông tin học kỳ một vào thông tin đầu vào có cải thiện macro-F1 và khả năng nhận diện lớp Dropout hay không? Hai câu hỏi phụ là mức cải thiện có nhất quán giữa Logistic Regression và Random Forest không, và các lỗi dự báo thường nhầm Dropout với Enrolled hay với Graduate.

Nhóm dự kiến kiểm tra giả thuyết rằng thông tin học kỳ một giúp phân biệt tốt hơn những sinh viên có cùng hồ sơ nhập học nhưng tiến độ học tập khác nhau. Đây là giả thuyết cần thực nghiệm, không phải kết luận đã được xác nhận cho bộ biến và cách chia tập của nhóm. Trường hợp cải thiện nhỏ, không rõ hoặc âm vẫn phải được báo cáo.

11. Đối tượng và phạm vi nghiên cứu

Đối tượng phân tích là dữ liệu lịch sử của cơ sở giáo dục đại học tại Portalegre, Bồ Đào Nha. Phân tích chính giữ ba nhãn Dropout, Enrolled và Graduate. Enrolled chỉ có nghĩa còn theo học tại thời điểm kết thúc thời lượng chuẩn của chương trình; không đồng nghĩa chắc chắn sẽ tốt nghiệp [1]. Nhóm không thu thập hồ sơ sinh viên của Trường Đại học Sài Gòn và không khẳng định mô hình đã phù hợp với sinh viên Việt Nam.

Hai tập biến được ký hiệu T0 và T1 để mô phỏng hai mức thông tin: hồ sơ đầu vào và hồ sơ đầu vào cộng thông tin học kỳ một. Bộ dữ liệu công khai không có ngày bỏ học để xác định đầy đủ ai còn theo học tại mốc T1. Do đó, nghiên cứu là đánh giá hồi cứu giá trị của thông tin, chưa phải kiểm chứng một hệ thống cảnh báo sớm trong vận hành. Các trường hợp đã bỏ học trước khi hết học kỳ một có thể tạo dấu hiệu quá dễ nhận diện; hạn chế này phải đi cùng kết luận.

11.1. Nguồn dữ liệu và phạm vi biến

Tệp data.csv hiện lưu từ UCI 697 có 4.424 dòng và 37 cột, gồm 36 biến đầu vào và Target. Tệp đã kiểm tra không có giá trị trống hoặc dòng trùng hoàn toàn. Số mẫu các lớp khớp P1, nhưng P1 mô tả 34 biến đầu vào và một nhãn. Hai cột điểm bằng cấp trước và điểm nhập học có trong bản UCI đang dùng; không vì số lớp giống nhau mà khẳng định mọi giá trị trùng bản trong bài báo. Nhóm sẽ lưu checksum, từ điển biến và phiên bản dữ liệu cùng kết quả [1], [6].

Bảng 11.1. Biến sử dụng tại hai mốc thông tin

Nhóm biến	**Các biến và nguyên tắc sử dụng**
T0 8 biến	Application mode; Application order; Course; Daytime/evening attendance; Previous qualification; Previous qualification (grade); Admission grade; Age at enrollment.
T1 14 biến	Toàn bộ T0 cộng sáu cột Curricular units 1st sem: (credited), (enrolled), (evaluations), (approved), (grade), (without evaluations).
Không dùng trong phân tích chính	Mọi cột học kỳ hai; Target trong đầu vào; Debtor, Tuition fees up to date, Scholarship holder do thời điểm cập nhật cần làm rõ; các biến còn lại ngoài danh sách để giữ phạm vi đối chứng thống nhất.

T0 có tám biến, T1 có mười bốn biến trước mã hóa. Các tên cột tiếng Anh được giữ trong mã nguồn để tránh nhầm nghĩa. Những cột mã hóa như Course và Application mode được xử lý theo bản chất phân loại, không coi khoảng cách giữa các mã số là khoảng cách có ý nghĩa. Số 0 trong biến học phần hoặc điểm không tự động được xem là thiếu; cần đọc mô tả dữ liệu trước khi xử lý. Target chỉ dùng làm nhãn, không làm biến đầu vào hoặc tiêu chí chọn biến trên toàn bộ dữ liệu.

12. Phương pháp nghiên cứu

12.1. Thiết kế so sánh và chia dữ liệu

Thiết kế chính gồm bốn cấu hình: LR–T0, LR–T1, RF–T0 và RF–T1, cộng một mô hình nền luôn chọn lớp phổ biến nhất. Chỉ số dòng được tạo một lần trước khi mã hóa và dùng chung cho mọi cấu hình. Dữ liệu được chia phân tầng thành tập huấn luyện 60%, tập xác thực 20% và tập kiểm tra 20%, với seed 42; số dòng thực tế sau làm tròn được lưu lại. Đây là tỷ lệ thiết kế thực nghiệm, không phải tỷ lệ chính xác kỳ vọng.

Trên tập huấn luyện, nhóm dùng kiểm định chéo phân tầng năm phần để chọn siêu tham số theo macro-F1. Trong mỗi fold, bộ mã hóa, bộ chuẩn hóa và mô hình chỉ được fit bằng phần huấn luyện của fold. Sau đó, mô hình với siêu tham số đã chọn được fit lại trên toàn bộ tập huấn luyện; tập xác thực dùng để so sánh cấu hình và chốt các quyết định bổ sung. Nhóm giữ nguyên mô hình đã fit để đánh giá cuối trên tập kiểm tra, không chọn lại tham số từ kết quả kiểm tra.

Mọi cấu hình chính được báo cáo, kể cả cấu hình có kết quả thấp. Các phép chia bổ sung để khảo sát độ ổn định, nếu thực hiện, phải chốt seed trước khi xem kết quả và được ghi là phân tích bổ sung. Không diễn giải việc chia ngẫu nhiên là đánh giá theo khóa tuyển sinh hoặc đánh giá tương lai, vì bản dữ liệu đang dùng không cung cấp đầy đủ trường để xây dựng giao thức đó.

12.2. Tiền xử lý và lựa chọn mô hình

Quy trình dự kiến là kiểm tra schema, khóa danh sách biến, chia dòng dữ liệu, fit pipeline trên tập huấn luyện, chọn tham số bằng kiểm định chéo, chốt cấu hình trên tập xác thực và cuối cùng đánh giá tập kiểm tra. Với biến phân loại, dùng one-hot encoding có xử lý giá trị chưa gặp. Với LR, các biến định lượng được chuẩn hóa từ thống kê tập huấn luyện; RF không cần bước chuẩn hóa tương tự. Nếu một phiên bản dữ liệu có thiếu giá trị, quy tắc điền phải được công bố và bộ điền cũng chỉ fit trong fold huấn luyện.

Nhóm dùng class_weight như một lựa chọn trong tìm siêu tham số, so sánh với không dùng trọng số. Không nhân đôi dữ liệu trước chia tập và không áp dụng SMOTE trên tập xác thực hoặc kiểm tra. Phương án chính chưa dùng SMOTE vì dữ liệu có nhiều mã phân loại và mục tiêu là đánh giá thông tin T0–T1; việc bổ sung SMOTE sẽ đòi hỏi thiết kế riêng để tránh tạo các giá trị mã không hợp lệ.

Bảng 12.1. Các cấu hình và phạm vi tìm tham số

Cấu hình	**Không gian tham số dự kiến**	**Vai trò**
Mô hình nền	Luôn dự báo lớp phổ biến nhất từ tập huấn luyện.	Mốc kiểm tra tối thiểu; không sử dụng nhãn kiểm tra để chọn lớp.
Logistic Regression	C: 0,1; 1; 10. class_weight: không dùng hoặc balanced. max_iter khởi đầu 2.000.	Đối chứng tuyến tính, chuẩn hóa biến định lượng trong pipeline.

Cấu hình	Không gian tham số dự kiến	Vai trò
Random Forest	200 cây. max_depth: 6 hoặc không giới hạn. min_samples_leaf: 2 hoặc 5. class_weight: không dùng hoặc balanced.	Đối chứng phi tuyến; cùng lưới và seed cho T0–T1.

Mỗi mô hình sử dụng cùng phạm vi tìm tham số ở T0 và T1. Nhóm ghi phiên bản Python, pandas, scikit-learn, seed, danh sách biến và tham số được chọn trong nhật ký chạy. Nếu LR chưa hội tụ, nhóm kiểm tra chuẩn hóa và tăng giới hạn số vòng lặp theo một quy tắc áp dụng đồng thời cho cả hai cấu hình, không sửa riêng cấu hình để làm đẹp kết quả. Hiện bảng trên là cấu hình dự kiến, chưa có kết quả chạy thử để khẳng định thời gian xử lý.

12.3. Chỉ số đánh giá và độ bất định

Macro-F1 là trung bình không trọng số của F1 ba lớp và là chỉ số chính; cách này không để lớp đông nhất tự quyết định toàn bộ điểm số. Với mỗi lớp, precision phản ánh tỷ lệ dự báo đúng trong những mẫu được gán vào lớp đó, recall phản ánh tỷ lệ nhận diện được trong các mẫu thực sự thuộc lớp, còn F1 kết hợp hai yếu tố. Nhóm đặc biệt xem precision, recall và F1 của Dropout, đồng thời giữ báo cáo của Enrolled và Graduate.

Balanced accuracy là trung bình recall của các lớp. Accuracy được báo cáo như thông tin bổ sung, cùng số lượng mẫu trong từng lớp và ma trận nhầm lẫn có nhãn trục rõ ràng. Nếu một cấu hình không dự báo được mẫu nào của một lớp, nhóm công bố tình trạng đó và quy ước xử lý phép chia cho 0 trong phần mềm; không bỏ lớp khỏi trung bình để nâng điểm số.

Giá trị bổ sung được đo bằng chênh lệch macro-F1 của T1 so với T0 cho từng loại mô hình trên cùng tập kiểm tra; tương tự với recall và F1 Dropout. Dự kiến dùng bootstrap ghép cặp phân tầng 1.000 lần, lấy mẫu lại chỉ số kiểm tra và dùng cùng chỉ số cho hai cấu hình, để tạo khoảng tin cậy percentile 95%. Khoảng này phản ánh biến động do tập kiểm tra đối với các mô hình đã fit, không bao gồm toàn bộ bất định do huấn luyện hoặc chuyển sang một trường khác. Nếu khoảng chênh lệch chứa 0, nhóm chỉ kết luận chưa có bằng chứng rõ về cải thiện trong thiết kế này.

Phân tích nhị phân bổ sung, nếu thực hiện, gộp Enrolled và Graduate thành "không mang nhãn Dropout ở thời điểm gắn nhãn", dùng cùng cách chia dòng và báo cáo tách biệt. Kết quả nhị phân không thay thế kết quả ba lớp. Nhóm không đặt mục tiêu bắt buộc accuracy trên 90%, vì chỉ số đó không đồng nghĩa phát hiện tốt sinh viên bỏ học và chưa có thực nghiệm riêng để cam kết.

12.4. Phân tích lỗi và giới hạn diễn giải

Nhóm dự kiến đối chiếu các mẫu Dropout bị bỏ sót, các cảnh báo sai và sự nhầm lẫn với Enrolled. Permutation importance trên tập xác thực sẽ hỗ trợ khảo sát vai trò nhóm biến học kỳ một; các biến tương quan có thể chia sẻ thông tin nên không diễn giải mức

quan trọng thấp là biến hoàn toàn vô ích. Mức quan trọng hoặc tương quan chỉ mô tả quan hệ dự báo, không chứng minh nguyên nhân gây bỏ học.

Các rủi ro chính gồm thiếu mốc bỏ học, thiếu thông tin đầy đủ về thời điểm cập nhật một số biến, khác biệt giữa các khóa và ngành, cùng hạn chế chuyển giao từ dữ liệu Bồ Đào Nha sang Việt Nam. Không tái nhận diện cá nhân và không dùng kết quả phân loại để tự động hạn chế quyền học tập. Trong phạm vi đề cương, đầu ra là bằng chứng nghiên cứu và mã nguồn tái lập, chưa phải hệ thống ra quyết định cho nhà trường.

13. Nội dung nghiên cứu và tiến độ thực hiện

13.1. Nội dung nghiên cứu

Nhóm xây dựng từ điển biến và bộ chỉ số dòng để tái lập hai mốc thông tin. Sau khi kiểm tra cách chia dữ liệu, nhóm huấn luyện mô hình nền cùng bốn cấu hình LR–T0, LR–T1, RF–T0 và RF–T1. Mỗi cấu hình cho một tệp dự đoán để tính chênh lệch giữa hai mốc và phân tích các trường hợp dự báo sai.

13.2. Tiến độ thực hiện

Kế hoạch dự kiến kéo dài 12 tuần tính từ thời điểm bắt đầu triển khai được thống nhất trong học phần. Các tuần dưới đây là mốc tương đối, không phải hạn nộp do giảng viên công bố. Phần tải và tổng hợp năm bài báo đã được chuẩn bị trong báo cáo; các bước thực nghiệm vẫn thuộc kế hoạch.

STT	Công việc chủ yếu	Thời gian (bắt đầu-kết thúc)	Người thực hiện
1	Đối chiếu toàn văn, hoàn thiện bảng và nhận xét theo tiêu chí.	Tuần 1–2	Lý Đức Huy, Nguyễn Quốc Huy
2	Khóa câu hỏi, nhãn, danh sách biến và protocol.	Tuần 3	Nguyễn Quốc Huy, Trần Nam Khang
3	Kiểm tra dữ liệu, tạo chỉ số dòng, chia tập và pipeline.	Tuần 4	Trần Nam Khang, Võ Quốc Khánh
4	Huấn luyện mô hình nền và bốn cấu hình; chọn tham số bằng CV.	Tuần 5–7	Võ Quốc Khánh
5	Đánh giá kiểm tra sau khi chốt; so sánh ghép cặp, phân tích lỗi.	Tuần 8–9	Lâm Trác Đạt, Võ Quốc Khánh
6	Khảo sát độ ổn định hoặc nhị phân nếu còn thời gian.	Tuần 10	Trần Nam Khang, Lâm Trác Đạt
7	Viết kết quả, rà nguồn và mã, chuẩn bị trình bày.	Tuần 11–12	Cả nhóm

Sau tuần 3, nhóm phải chốt được danh sách biến và cách đánh giá trước khi huấn luyện. Sau tuần 7, nhóm phải có các cấu hình được chọn mà chưa dựa vào điểm kiểm tra. Nếu phát hiện sai quy trình hoặc trùng dòng giữa các tập, nhóm sửa lỗi và chạy lại các cấu hình bị ảnh hưởng, ghi lý do trong nhật ký; không chỉ thay một con số trong báo cáo.

14. Sản phẩm khoa học và công nghệ của đề tài

STT	Chủng loại sản phẩm	Yêu cầu về chất lượng cần đạt của sản phẩm	Số lượng (đơn vị)
1	Bản thảo bài báo khoa học dự kiến	Trình bày câu hỏi, dữ liệu, giao thức, kết quả thực nghiệm và các giới hạn. Số liệu trong bản thảo phải truy được về tệp kết quả.	01 bản thảo
2	Bộ mã tái lập thí nghiệm và từ điển biến	Tạo đúng T0/T1, lưu chỉ số dòng, cấu hình tiền xử lý và tham số từng mô hình.	01 bộ
3	Bộ kết quả và phân tích lỗi	Gồm kết quả của bốn cấu hình và mô hình nền, chỉ số từng lớp, ma trận nhầm lẫn và khoảng tin cậy cho chênh lệch T1–T0.	01 bộ

14.1. Kết quả dự kiến và tiêu chí diễn giải

Từ P3 và P4, nhóm kỳ vọng T1 có thể cung cấp tín hiệu tốt hơn T0, nhất là qua tiến độ hoàn thành học phần. Tuy nhiên, mức cải thiện, mô hình tốt hơn và khả năng phân biệt lớp Enrolled vẫn chưa biết. Nếu T1 cải thiện nhất quán và khoảng chênh lệch hỗ trợ kết luận đó, nhóm sẽ mô tả lợi ích trong giới hạn bộ dữ liệu và giao thức. Nếu cải thiện chỉ xuất hiện ở accuracy hoặc lớp Graduate mà recall Dropout giảm, nhóm sẽ không gọi đó là cải thiện đồng đều.

Nếu hai mô hình cho kết quả trái chiều, nhóm phân tích cách khai thác quan hệ tuyến tính và phi tuyến, độ bất định và lỗi từng lớp. Nếu chênh lệch không rõ hoặc T1 kém hơn, báo cáo vẫn có giá trị khi xác định điều kiện mà thêm thông tin không đem lại lợi ích như kỳ vọng. Không suy từ kết quả hồi cứu sang kết luận rằng một biện pháp hỗ trợ sẽ làm giảm tỷ lệ bỏ học.

Đề tài có cơ sở khả thi ở việc đã có dữ liệu công khai, đã lưu năm bài toàn văn, có hai mô hình chuẩn và thiết kế so sánh giới hạn. Khối lượng được chia thành các sản phẩm có thể kiểm tra trong kế hoạch 12 tuần. Tuy nhiên, chưa có cơ sở để gán một xác suất thành công cụ thể hoặc cam kết mức chính xác 90%; tính khả thi ở đây được đánh giá bằng khả năng tiếp cận dữ liệu, triển khai quy trình và trả lời câu hỏi nghiên cứu.

Cam kết của chủ nhiệm đề tài: kết quả thực hiện đề tài này không trùng lặp với sản phẩm, công trình khoa học khác đã công bố.

15. Khả năng ứng dụng và phát triển của đề tài

Bộ mã và từ điển biến giúp người học kiểm tra tác động của việc bổ sung kết quả học kỳ một đối với từng lớp sinh viên. Người đọc có thể thay đổi mô hình hoặc tập biến, chạy lại trên cùng chỉ số dòng và so sánh các sai khác với kết quả ban đầu.

Để đánh giá khả năng sử dụng tại một cơ sở đào tạo khác, cần thu thập thời điểm rời học, xác định danh sách sinh viên còn theo học ở từng mốc và thống nhất định nghĩa nhãn. Bước phát triển tiếp theo là kiểm định trên một khóa tuyển sinh mới, phân tích cảnh báo sai và đánh giá cùng cán bộ học vụ trước khi xem xét ứng dụng hỗ trợ sinh viên.

16. Kinh phí thực hiện đề tài NCKH của sinh viên

Nhóm dự kiến sử dụng dữ liệu công khai, phần mềm Python và máy tính cá nhân. Mức kinh phí đăng ký, nguồn cấp và từng khoản dự toán chờ nhóm thống nhất với cán bộ hướng dẫn theo loại đề tài.

Tổng kinh phí dự kiến: [Chờ xác nhận] đồng. Ngân sách Nhà nước: [Điền]. Các nguồn khác: [Điền]. Số tiền bằng chữ: [Điền khi chốt dự toán]. Đơn vị tính: đồng.		
TT	Nội dung chi	Kinh phí
1	Chi tiền công thực hiện đề tài: (ghi tổng số theo mục này)	
	- Thù lao chủ nhiệm đề tài, quản lý chung	
	- Điều tra, khảo sát ban đầu, xây dựng đề cương, thuyết minh...	
	- Khảo sát, nghiên cứu thực địa, tổng hợp tài liệu, viết báo cáo…	
2	Chi thuê khoán chuyên môn: (ghi tổng số theo mục này)	
	- Thuê nhập liệu, xử lý số liệu	
	- Phân tích mẫu thí nghiệm, đo đạc, xử lý kết quả đo…	
	- Các công việc thuê khác	
3	Mua nguyên vật liệu: (ghi tổng số theo mục này- phải có hóa đơn, xuất VAT nếu vượt quá 200.000đ) - Hóa chất - Dụng cụ - Tài liệu tham khảo - Các nguyên vật liệu khác phục vụ nghiên cứu	
4	Chi phí khác: (ghi tổng số theo mục này- phải có hóa đơn, xuất VAT nếu vượt quá 200.000đ) - Phí tham dự hội nghị/hội thảo, - In ấn, pho to - Thuê phương tiện, địa điểm nghiên cứu, ...	
Tổng số		

Thành phố Hồ Chí Minh, ngày …… tháng …… năm ……

Duyệt của Khoa	**Xác nhận của Chủ tịch Hội đồng xét duyệt** *(chỉ dùng sau khi đã xét duyệt)*	**Cán bộ hướng dẫn** *(Ký và ghi rõ họ tên)*	**Chủ nhiệm đề tài** *(Ký và ghi rõ họ tên)*

XÁC NHẬN CỦA TRƯỜNG ĐẠI HỌC SÀI GÒN

TL. HIỆU TRƯỞNG

TRƯỞNG PHÒNG QUẢN LÝ KHOA HỌC

(Ký, ghi rõ họ tên)

Tài liệu tham khảo

[1] V. Realinho, J. Machado, L. Baptista, and M. V. Martins, “Predicting Student Dropout and Academic Success,” *Data*, vol. 7, no. 11, Art. no. 146, 2022, doi: 10.3390/data7110146.

[2] Nông Thị Hoa, “Ứng dụng các mô hình học máy vào dự đoán tình trạng bỏ học của sinh viên,” *TNU Journal of Science and Technology*, vol. 230, no. 7, pp. 120–125, 2025, doi: 10.34238/tnu-jst.12201.

[3] M. V. Martins, L. Baptista, J. Machado, and V. Realinho, “Multi-Class Phased Prediction of Academic Performance and Dropout in Higher Education,” *Applied Sciences*, vol. 13, no. 8, Art. no. 4702, 2023, doi: 10.3390/app13084702.

[4] O. Goren, L. Cohen, and A. Rubinstein, “Early Prediction of Student Dropout in Higher Education using Machine Learning Models,” in *Proceedings of the 17th International Conference on Educational Data Mining*, 2024, pp. 349–359, doi: 10.5281/zenodo.12729834.

[5] C. H. Cho, Y. W. Yu, and H. G. Kim, “A Study on Dropout Prediction for University Students Using Machine Learning,” *Applied Sciences*, vol. 13, no. 21, Art. no. 12004, 2023, doi: 10.3390/app132112004.

[6] V. Realinho, M. V. Martins, J. Machado, and L. Baptista, “Predict Students’ Dropout and Academic Success,” UCI Machine Learning Repository, 2021, doi: 10.24432/C5MC89. [Data set].